

# About Neural Network

Viet Hoang Duc

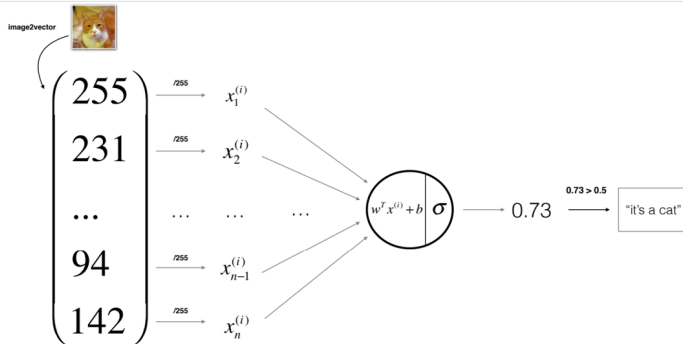
April 2019

- Logistic Regression.
- Softmax Regression.
- Shallow Neural Network.
- Deep Neural Network.

# Logistic Regression

- Đầu ra của logistic regression thể hiện dưới dạng xác suất.
- Cho tập điều kiện  $x$ , mục tiêu tìm  $\hat{y} = P(y = 1|x)$
- Ví dụ:
  - Xác suất 1 email là spam dựa trên người gửi, số lỗi chính tả hoặc số lần lặp lại của từ “offer”, “free gift”...
  - Xác suất 1 khối u là ác tính hay không dựa trên đặc điểm ví dụ như kích thước khối u, khối u nằm ở đâu.
  - Xác định là ảnh con mèo dựa trên thông tin hình ảnh.

# Logistic Regression



# Logistic Regression

- Đầu ra dự đoán của logistic regression thường được viết dưới dạng:

$$\hat{y} = f(x) = \theta(\mathbf{w}^T x) \quad (*)$$

- Trong đó:
  - $\hat{y}$  là giá trị dự đoán.  $0 \leq \hat{y} \leq 1$
  - $\theta$  là logistic function.
  - $\mathbf{w}^T$  là tham số.
- Trong phần này ta đề cập đến hàm sigmoid:

$$\theta(s) = \frac{1}{1 + e^{-s}} \triangleq \sigma(s)$$

# Logistic Regression

## Hàm mất mát và phương án tối ưu

- Tập dữ liệu (data set) nhận được:  $\{(x^1, y^1), \dots, (x^m, y^m)\}$ . Tìm  $\hat{y}^{(i)} \approx y^{(i)}$ .
- $\hat{y}^{(i)} = \sigma(z^{(i)})$  với  $\sigma(z^{(i)}) = \frac{1}{1+e^{-z^{(i)}}}$  và  $z^{(i)} = \mathbf{w}^T x^{(i)}$ .
- Loss Function:

$$\mathcal{L}(\hat{y}, y) = -(y \log \hat{y} + (1 - y) \log(1 - \hat{y}))$$

- Cost function:

$$J(\mathbf{w}) = -\frac{1}{m} \sum_{i=1}^m \mathcal{L}(\hat{y}^{(i)}, y^{(i)}) = -\frac{1}{m} \sum_{i=1}^m (y \log \hat{y} + (1 - y) \log(1 - \hat{y}))$$

# Logistic Regression

## Forward Propagation

- Gradient descent, cần tìm đạo hàm  $J$  đối với  $\mathbf{w}$ :

$$\mathbf{w} = \mathbf{w} - \eta \frac{\partial J(\mathbf{w}, b)}{\partial \mathbf{w}}$$

- Cost function:

$$J(\mathbf{w}) = -\frac{1}{m} \sum_{i=1}^m \mathcal{L}(\hat{y}^{(i)}, y^{(i)})$$

- Loss function:

$$\mathcal{L}(\hat{y}, y) = -(y \log \hat{y} + (1 - y) \log(1 - \hat{y}))$$

- Sigmoid function:

$$\hat{y} = \sigma(z) \quad \text{với} \quad z = \mathbf{w}^T \mathbf{x}$$

# Logistic Regression

## Backward Propagation

- Đạo hàm  $J$  đối với  $\mathbf{w}$ :

$$\frac{\partial J(\mathbf{w})}{\partial \mathbf{w}} = \frac{\partial J(\mathbf{w})}{\partial \mathcal{L}(\hat{y}, y)} \times \frac{\partial \mathcal{L}(\hat{y}, y)}{\partial \hat{y}} \times \frac{\partial \hat{y}}{\partial z} \times \frac{\partial z}{\partial \mathbf{w}} \quad (1)$$

- Đạo hàm của  $J$  đối với  $\mathcal{L}$ :

$$\frac{\partial J(\mathbf{w})}{\partial \mathcal{L}(\hat{y}, y)} = -\frac{1}{m} \sum_{i=1}^m \frac{\partial \mathcal{L}(\hat{y}^{(i)}, y^{(i)})}{\partial \hat{y}^{(i)}} \quad (2)$$

- Đạo hàm của  $\mathcal{L}$  đối với  $\hat{y}$ :

$$\frac{\partial \mathcal{L}(\hat{y}, y)}{\partial \hat{y}} = -\left(\frac{y}{\hat{y}} - \frac{1-y}{1-\hat{y}}\right) = \frac{\hat{y} - y}{\hat{y}(1-\hat{y})} \quad (3)$$



# Logistic Regression

## Backward Propagation

- Đạo hàm của  $\hat{y}$  đối với biến  $z$

$$\begin{aligned}\frac{\partial \hat{y}}{\partial z} &= \sigma'(z) = \frac{e^{-z}}{(1 + e^{-z})^2} \\ &= \frac{1}{1 + e^{-z}} \frac{e^{-z}}{1 + e^{-z}} = \sigma(z)(1 - \sigma(z)) \\ &= \hat{y}(1 - \hat{y})\end{aligned}\tag{4}$$

- Đạo hàm của  $z$  đối với  $\mathbf{w}$ :

$$\frac{\partial z}{\partial \mathbf{w}} = \mathbf{x}\tag{5}$$

# Logistic Regression

## Backward Propagation

- Thay (2) (3) (4) (5) vào (1):


$$\frac{\partial J(\mathbf{w})}{\partial \mathbf{w}} = -\frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}) x^{(i)}$$

- Công thức cập nhật theo Gradient Descent:

$$\mathbf{w} = \mathbf{w} - \eta \frac{\partial J(\mathbf{w}, b)}{\partial \mathbf{w}}$$

Với  $\eta$  là learning rate.

# Softmax Regression




Softmax Regression biểu diễn dưới dạng Neural Network

# Softmax Regression

## Multi-class Classification

Figure: One-vs-one biểu diễn dưới dạng Neural Network



# Softmax Regression


## Multi-class Classification

- Xây dựng nhiều bộ binary classifiers cho từng cặp classes. Bộ thứ nhất phân biệt class 1 và class 2, bộ thứ 2 phân biệt class 1 và class 3, ... Tuy nhiên, khi đó cần rất nhiều bộ binary classifiers.
- Số lượng bộ cần dùng là  $\frac{n(n-1)}{2}$

# Softmax Regression

## Multi-class Classification

Figure: One-vs-one biểu diễn dưới dạng Neural Network





# Softmax Regression

## Multi-class Classification

- Phương pháp này còn được gọi là one-hot coding. Ta sẽ xây dựng những bộ classifiers để phân loại  $C$  classes. Classifiers thứ nhất phân biệt class 1 vs not class 1, tương tự như thế với các classes còn lại
- Phương pháp one-vs-rest theo góc nhìn xác suất, một điểm dữ liệu có thể được dự đoán thuộc vào class  $1, 2, \dots, C$  với xác suất lần lượt là  $p_1, p_2, \dots, p_C$ . Tuy nhiên, tổng các xác suất này có thể không bằng 1.

# Softmax Regression

Figure: Multi-class classification với Logistic Regression và one-vs-rest.



$w_{0j}$ : biases, don't forget!

$d$ : data dimension

$C$ : number of classes

$\mathbf{x} \in \mathbb{R}^{d+1}$

$\mathbf{W} \in \mathbb{R}^{(d+1) \times C}$

$z_i = \mathbf{w}_i^T \mathbf{x}$

$\mathbf{z} = \mathbf{W}^T \mathbf{x} \in \mathbb{R}^C$

$a_i = \text{sigmoid}(z_i) \in \mathbb{R}$

$0 < a_i < 1$

$$a^{(i)} = \text{sigmoid}(z^{(i)}) = \text{sigmoid}(\mathbf{W}^{(i)T} \mathbf{x})$$



# Softmax Regression

## Hàm mất mát và phương án tối ưu

Tập dữ liệu (data set) nhận được:  $\{(x^1, y^1), \dots, (x^m, y^m)\}$ . Và  $y^{(i)} \in \{1, 2, \dots, C\}$ . Với  $C$  là số lượng classes. Tìm  $\hat{y}^{(i)} \approx y^{(i)}$ . Ví dụ trong bộ dữ liệu MNIST thì  $C = 10$ . Cho một điểm dữ liệu  $x$ , mục tiêu tìm  $\hat{y} = P(y = k|x), \forall k = 1, \dots, C$ . Do ta cần  $\sum_{i=1}^C \hat{y}^{(i)} = 1$  nên nếu áp dụng hàm sigmoid như Logistic Regression thì tổng các xác suất không bằng một. Phương án là sử dụng một hàm số khác thoả mãn:

- Hàm đồng biến do  $z^{(i)}$  càng lớn thì xác suất rơi vào class  $i$  càng tăng cao.
- Do  $z^{(i)}$  có thể nhận giá trị âm nên hàm số cần chắc chắn cho ra giá trị của  $\hat{y}^{(i)}$  chạy trong đoạn 0 đến 1.

# Softmax Regression

Hàm mất mát và phương án tối ưu

- Hàm số ta cần tìm:

$$\hat{y}^{(i)} = \begin{bmatrix} P(y = 1|x; \mathbf{W}) \\ P(y = 2|x; \mathbf{W}) \\ \vdots \\ P(y = C|x; \mathbf{W}) \end{bmatrix} = \theta(z^{(i)}) = \frac{e^{z^{(i)}}}{\sum_{j=1}^C e^{z_j^{(i)}}} \quad (6)$$

- Trong đó:

$$z^{(i)} = \mathbf{W}^T \mathbf{x}^{(i)}$$

# Softmax Regression

## Hàm mất mát và phương án tối ưu

Ví dụ trong tập dữ liệu MNIST, input là một ảnh grayscale kích thước 28x28 px.  $x$  là một vector (784,1) có output là  $y$  là một vector (10,1).

Suy ra:

$$z = \mathbf{W}^T x$$

Với:

- $z$  có kích thước (10,1).
- $\mathbf{W}$  có kích thước (784,10).

Cần chú ý rằng trong Logistic Regression chỉ có 1 node ở output layer nên trong trường hợp đó, tham số mô hình chỉ là 1 vector  $\mathbf{w}$  có kích thước (784,1). Tuy nhiên trong bài toán này, có 10 node ở output layer nên ta có ma trận trọng số  $\mathbf{W} = [\mathbf{w}_0, \mathbf{w}_1, \dots, \mathbf{w}_9]$ .

# Softmax Regression

Hàm mất mát và phương án tối ưu

Ví dụ với  $C = 4$ :  $z = \begin{bmatrix} 5 \\ 9 \\ -4 \\ 3 \end{bmatrix}$      $\hat{y} = \theta(z) = \begin{bmatrix} 0.018 \\ 0.980 \\ 0.000 \\ 0.002 \end{bmatrix}$  và     $y = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$

Hàm mất mát - Loss Function:

$$\begin{aligned}\mathcal{L}(\hat{y}, y) &= - \sum_{i=1}^C y_i \log(\hat{y}_i) \\ &= - \log 0.980\end{aligned}$$

# Softmax Regression

Hàm mất mát và phương án tối ưu

Hàm chi phí - cost function:

$$\begin{aligned} J(\mathbf{W}) &= \frac{1}{m} \sum_{i=1}^m \mathcal{L}(\hat{y}^{(i)}, y^{(i)}) \\ &= -\frac{1}{m} \sum_{i=1}^m \sum_{j=1}^C y_j^{(i)} \log(\hat{y}_j^{(i)}) \end{aligned}$$

# Softmax Regression

## Hàm mất mát và phương án tối ưu

- Có  $m$  điểm dữ liệu:  $\{(x^1, y^1), \dots, (x^m, y^m)\}$   $x^{(i)} \in \mathbb{R}^{n_x}$

$$X = \begin{bmatrix} | & | & & | \\ x^{(1)} & x^{(2)} & \dots & x^{(m)} \\ | & | & & | \end{bmatrix}$$
$$X.shape = (n_x, m)$$

- Tương tự:

$$Y = [y^{(1)}, y^{(2)}, \dots, y^{(m)}] \quad y^{(i)} \in \mathbb{R}^C$$
$$Y.shape = (C, m)$$

- Và:

$$Z = [z^{(1)}, z^{(2)}, \dots, z^{(m)}] \quad z^{(i)} \in \mathbb{R}^C$$
$$Z.shape = (C, m)$$

# Softmax Regression

## Công thức cập nhật Gradient Descent

Giả sử rằng chúng ta sử dụng SGD, công thức cập nhật cho ma trận trọng số  $\mathbf{W}$  sẽ là:

$$\mathbf{W} = \mathbf{W} + \eta x^{(i)} (y^{(i)} - \hat{y}^{(i)})$$